NOSQL VS SQL

肖子彤 张倬 谭凌霄

数据库发展史

the History of Databases

数据分类

- 结构化数据
- 非结构化数据
- 半结构化数据

发展阶段

- 一枝独霸：SQL
- 异军突起： NoSQL
- 多极并起，各有千秋

研究方法

Research Methods

环境

- OS：Ubuntu 14.0.2
- CPU:Intel(R) Core(TM) i5-4210M CPU @ 2.40GHZ
- RAM：4G
- Storage: 20G HDD
- SQL：MySQL-5.6.0
- NoSQL：MongoDB-2.4.9

工具

- mysqlslap
- smack
- Sysbench
- YCSB(The Yahoo! Cloud Serving Benchmark)
- script

衡量标准

- 操作执行速度（时间尺度）
- 数据文件大小（空间尺度）

结构化数据集实验

Experiment on Structured Datasets

数据集选择

- 使用脚本生成的统一的结构化数据集
- 使用现有实际数据集，（如上海电信某天流量数据集等）

经过比较，选择了以脚本生成的数据集
可以对表的结构进行更细致的定制
实现sql和nosql中数据属性和规模统一

场景

- 场景S1：100%插入。用来加载测试数据
- 场景S2：写多读少 90% 更新 10%读
- 场景S3：混合读写60%读，30%插入,10% 更新
- 场景S4：读多写少 90% 读，10% 插入、更新
- 场景S5：100%读

操作过程

SQL

- 生成sql脚本
- 预热
- 运行mysqlslap调用sql脚本进行检测
- 查看数据文件大小

NOSQL

- 定制workloads
- 预热
- 运行ycsb加载workloads进行检测
- 查看数据文件大小

运行截图（MYSQLSLAP）

```
ubuntu@VM-152-178-ubuntu:~$ mysqlslap -u root -p --create-schema mysql -T
Enter password:
Benchmark
        Average number of seconds to run all queries: 0.000 seconds
        Minimum number of seconds to run all queries: 0.000 seconds
        Maximum number of seconds to run all queries: 0.000 seconds
        Number of clients running queries: 1
        Average number of queries per client: 0


User time 0.00, System time 0.00
Maximum resident set size 1784, Integral resident set size 0
Non-physical pagefaults 494, Physical pagefaults 0, Swaps 0
Blocks in 0 out 0, Messages in 0 out 0, Signals 0
Voluntary context switches 6, Involuntary context switches 30
ubuntu@VM-152-178-ubuntu:~$
```

运行截图（YCSB）

```
[OVERALL], RunTime(ms), 411.0
[OVERALL], Throughput(ops/sec), 0.0
[CLEANUP], Operations, 1.0
[CLEANUP], AverageLatency(us), 4398.0
[CLEANUP], MinLatency(us), 4396.0
[CLEANUP], MaxLatency(us), 4399.0
[CLEANUP], 95thPercentileLatency(us), 4399.0
[CLEANUP], 99thPercentileLatency(us), 4399.0
[INSERT-FAILED], Operations, 1.0
[INSERT-FAILED], AverageLatency(us), 86112.0
[INSERT-FAILED], MinLatency(us), 86080.0
[INSERT-FAILED], MaxLatency(us), 86143.0
[INSERT-FAILED], 95thPercentileLatency(us), 86143.0
[INSERT-FAILED], 99thPercentileLatency(us), 86143.0
[INSERT], Operations, 0.0
[INSERT], AverageLatency(us), NaN
[INSERT], MinLatency(us), 9.2233720368547 76E18
[INSERT], MaxLatency(us), 0.0
[INSERT], 95thPercentileLatency(us), 0.0
[INSERT], 99thPercentileLatency(us), 0.0
[INSERT], Return=ERROR, 1
ubuntu@VM-152-178-ubuntu:~/ycsb-0.7.0$ ./bin/ycsb load mongodb -P workloads/workloada -p recordcount=100
```

代码片段（SQL）

```
62
63 #CONFIG = {gencreate: 1}
64 #CONFIG = {genread: 0.1, genupdate: 0.9}
65 CONFIG = {genread: 0.6,genupdate: 0.1,genwrite: 0.3}
66 #CONFIG = {genread: 0.9,genupdate: 0.1}
67 #CONFIG = {genread: 1}
68
69
70 if __name__ == '__main__':
71     randbox = []
72     for i in CONFIG:
73         randbox += [i(int(CONFIG[i] * TOTAL_NUM))] * int(CONFIG[i] * TOTAL_NUM + 1)
74     random.shuffle(randbox)
75     #print randbox
76     fout = open(OUTFILE, 'w+')
77     for gen in randbox:
78         try:
79             query = gen.next()
80             fout.write(query)
81         except StopIteration:
82             pass
83     fout.close()
```

代码片段（NOSQL）

```
25 count = " -p recordcount = "
26 outfile = "" #" > "
27
28 if __name__ == "__main__":
29
30     rec = "top -n 1 -b | grep mongo >> "
31
32     rec += sys.argv[1]
33     ycsb = int(sys.argv[2])
34     thread += sys.argv[3]
35     count += sys.argv[4]
36     #outfile += sys.argv[5]
37
38     t0=threading.Thread(target=record,args=(1,0.1))
39     t1=threading.Thread(target=start_ycsb)
40
41     t1.start()
42     t0.start()
43
44
```

时间性能比较

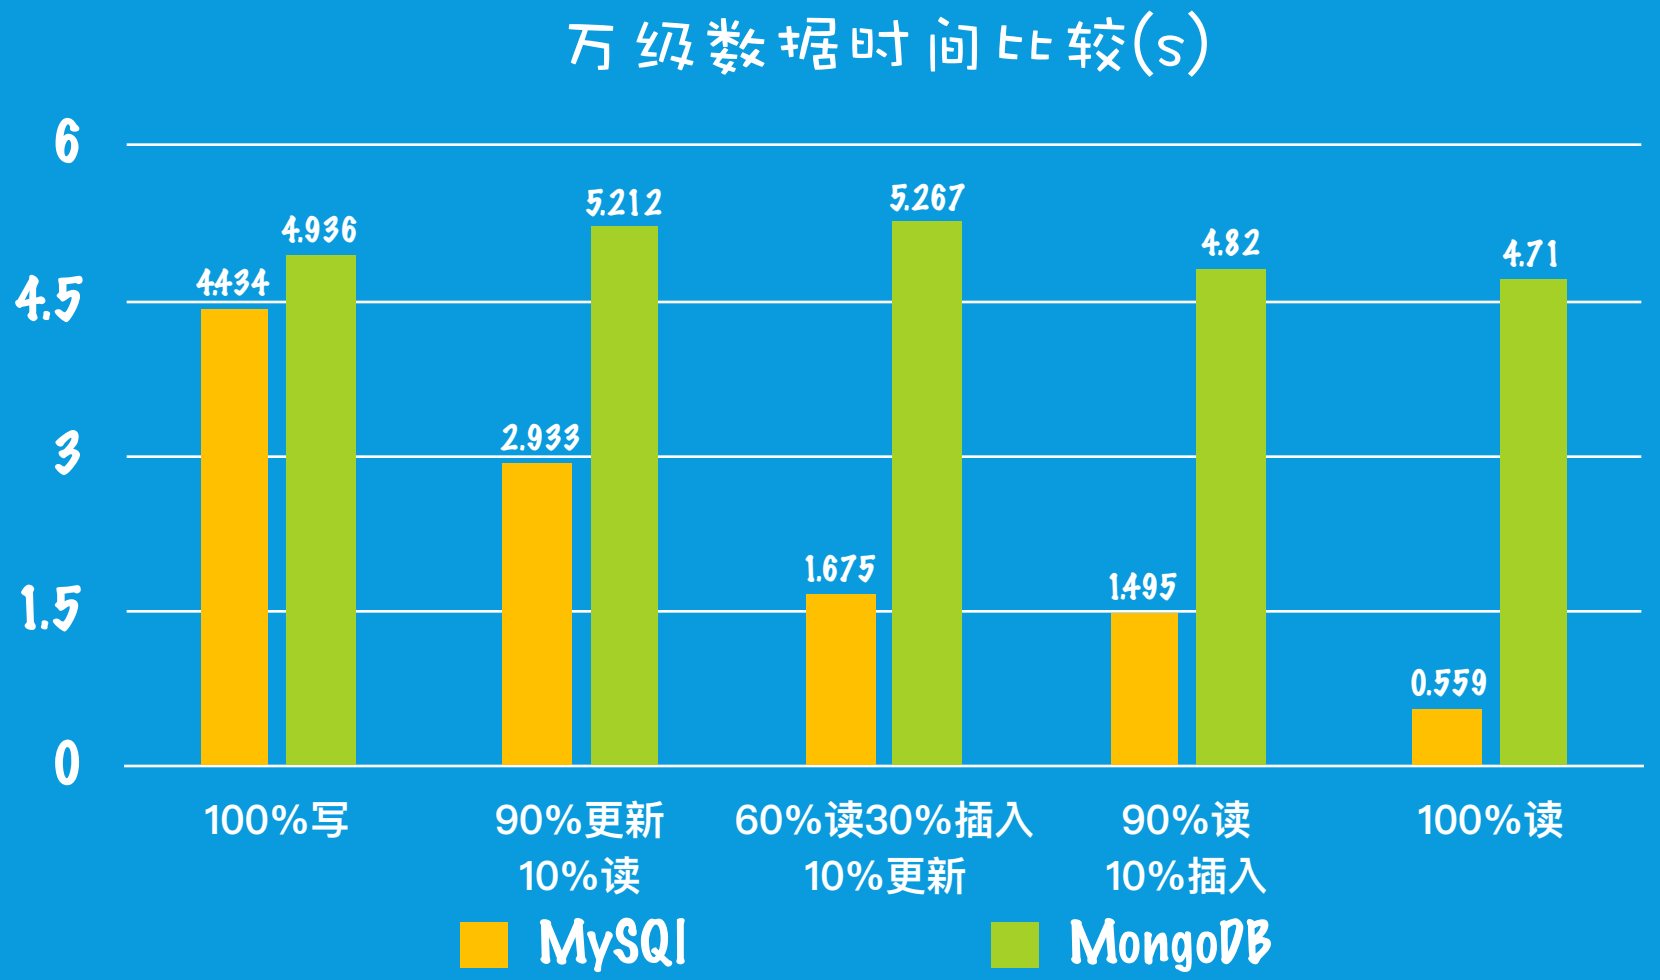
万级数据时间比较(s)
6
4.5
3
1.5
0
4.434
4.936
2.933
5.212
1.675
5.267
1.495
4.82
0.559
4.71
100%写
90%更新
10%读
60%读30%插入
10%更新
90%读
10%插入
100%读
MySQl
MongoDB

时间性能比较

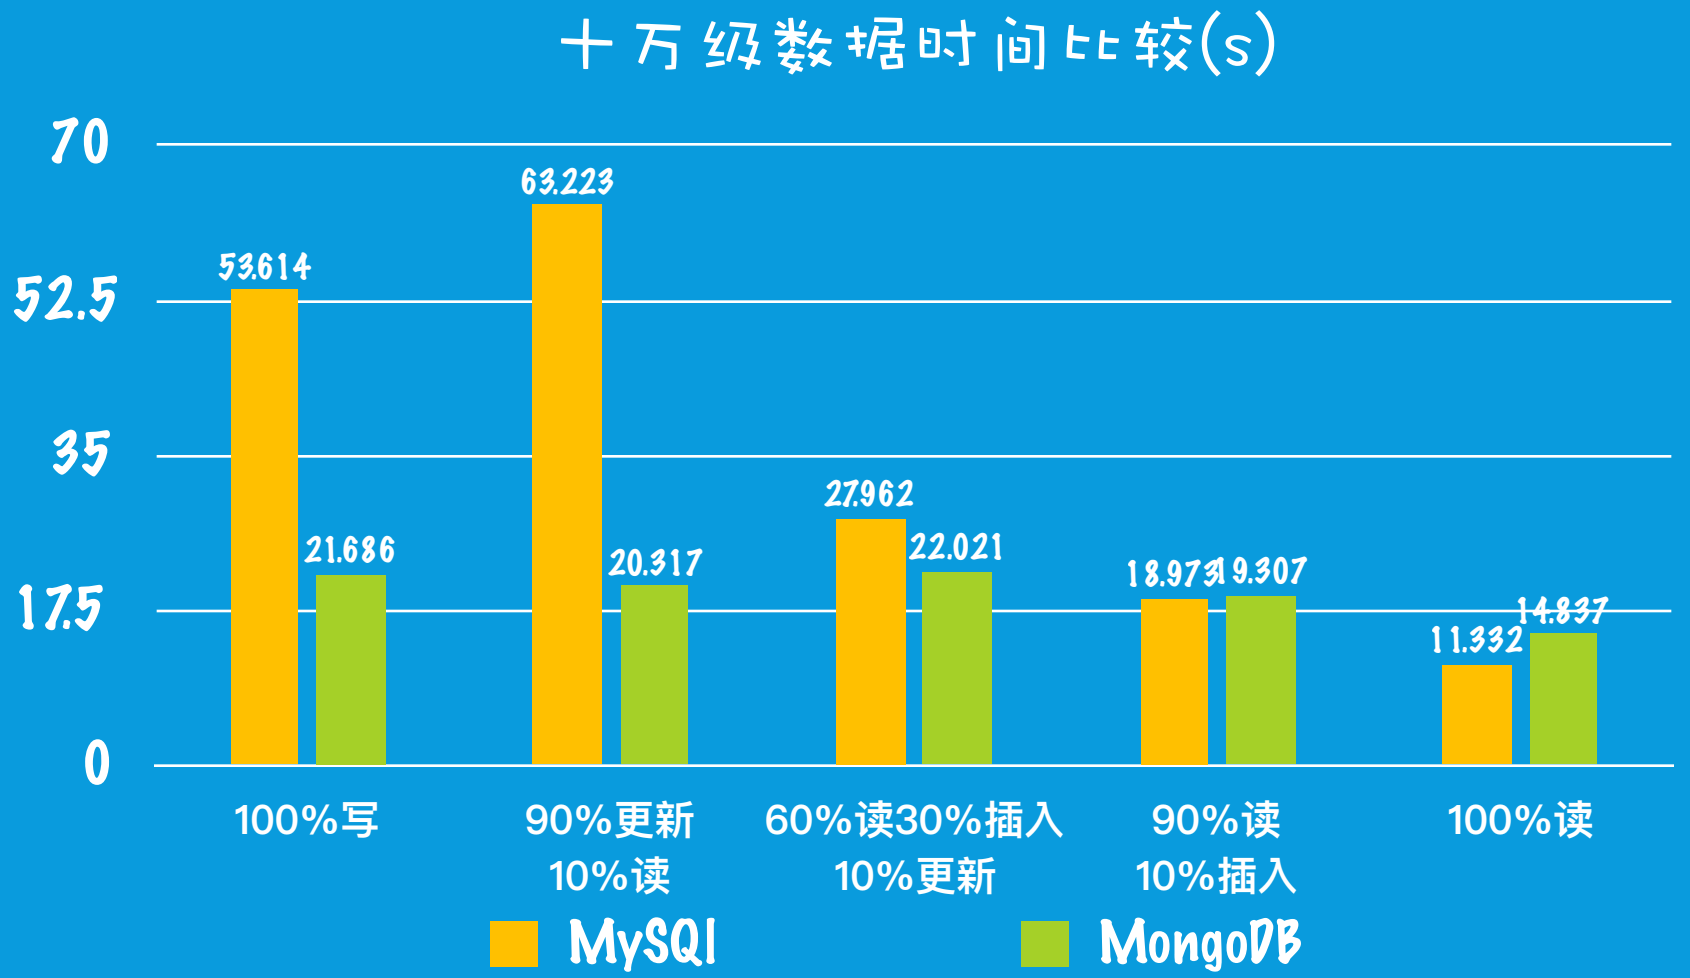
十万级数据时间比较(s)
70
52.5
35
17.5
0
53.614
21.686
63.223
20.317
27.962
22.021
18.973
19.307
11.332
14.837
100%写
90%更新
10%读
60%读30%插入
10%更新
90%读
10%插入
100%读
MySQl
MongoDB

时间性能比较

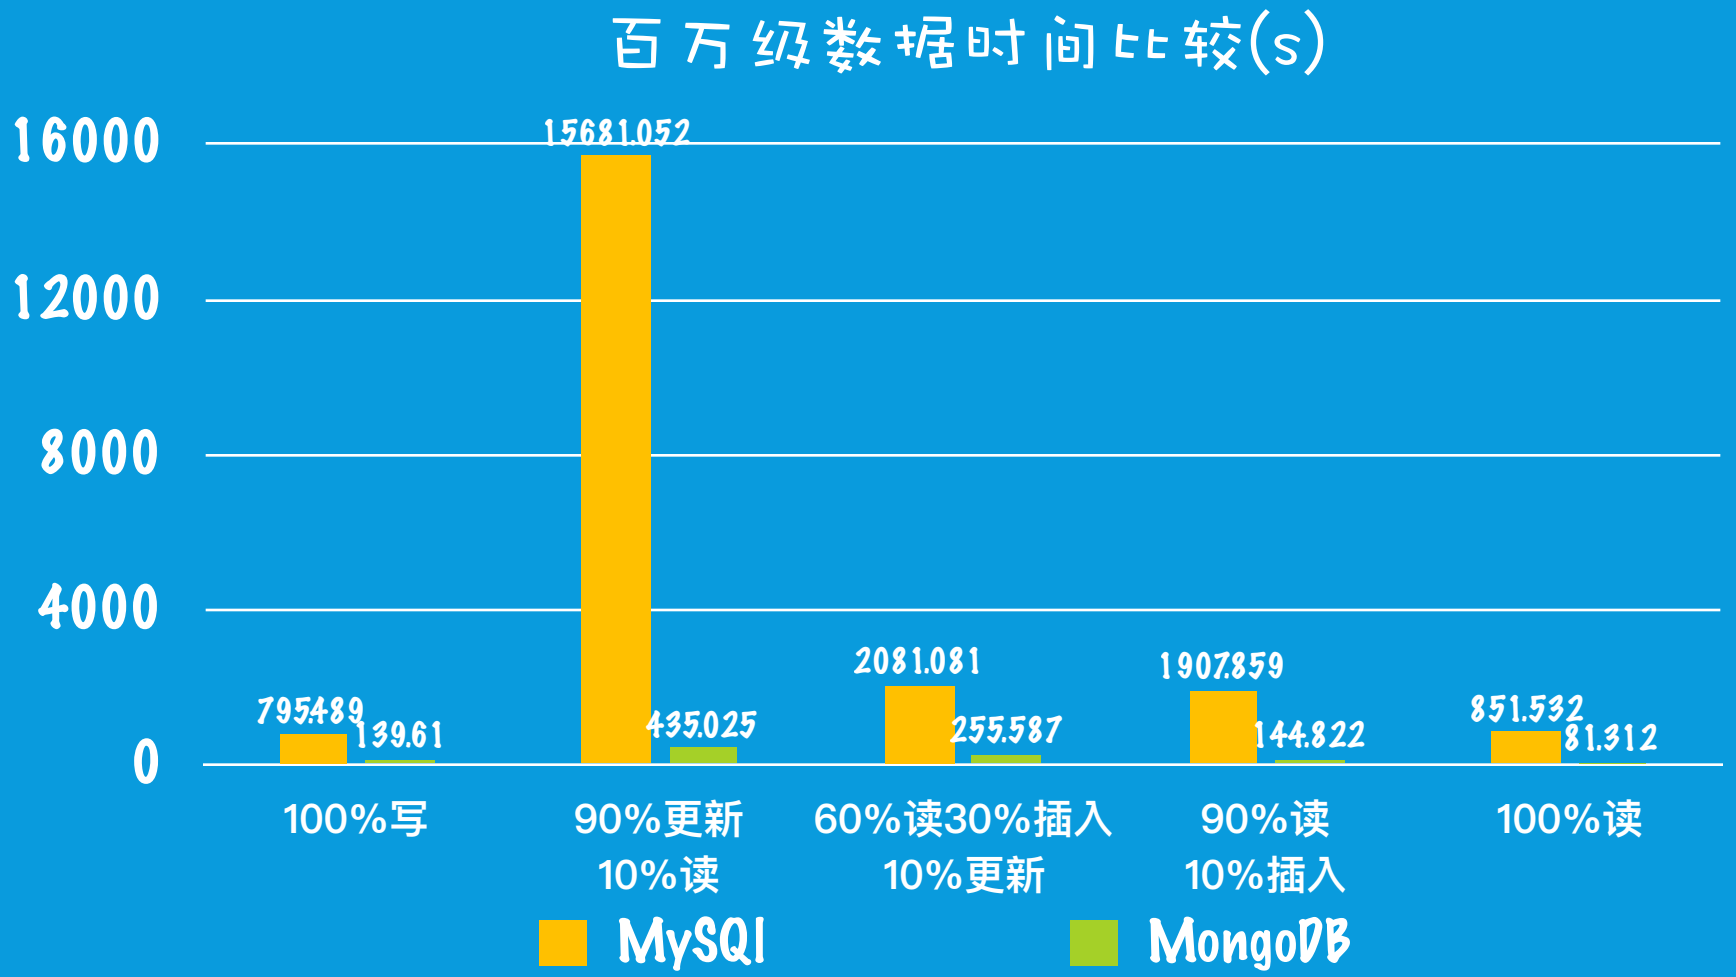
百万级数据时间比较(s)
16000
12000
8000
4000
0
795.489
139.61
15681.052
435.025
2081.081
255.587
1907.859
144.822
851.532
81.312
100%写
90%更新
10%读
60%读30%插入
10%更新
90%读
10%插入
100%读
MySQl
MongoDB

空间占用

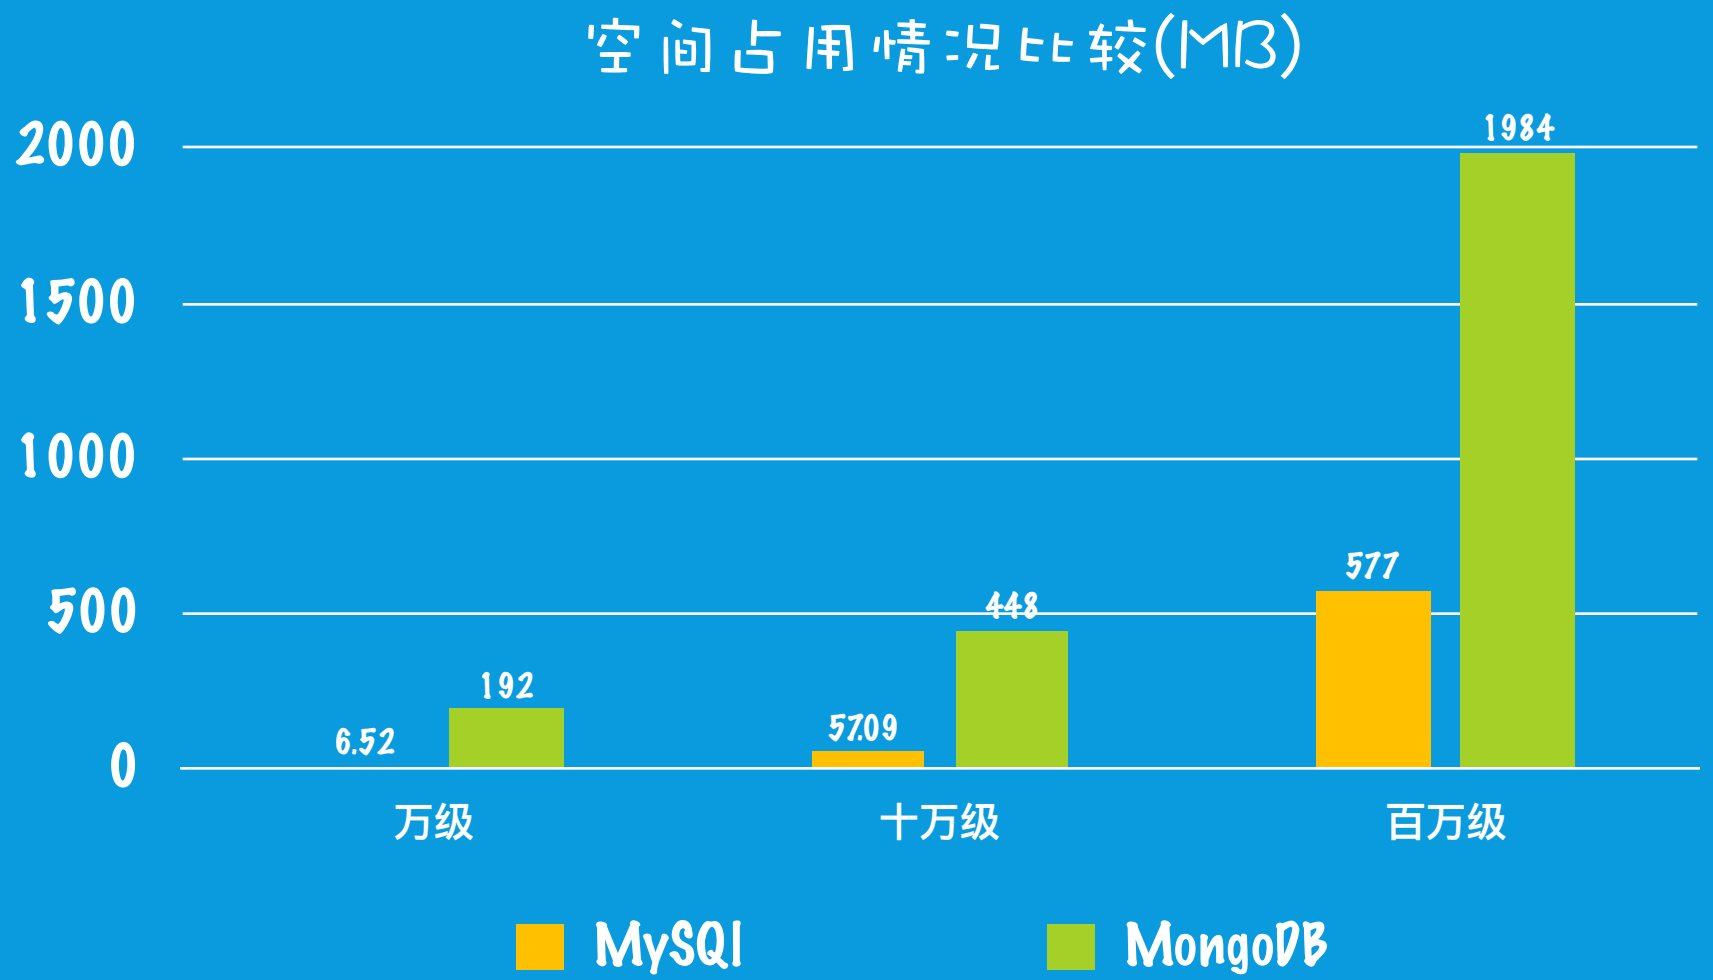
空间占用情况比较(MB)
2000
1500
1000
500
0
6.52
192
57.09
448
577
1984
万级
十万级
百万级
MySQl
MongoDB

结论

- 当数据规模较小时mysql操作速度略优于mongodb
- 对于大规模数据集MongoDB在操作速度上有极大的优势
- 但其是以巨大的索引空间来获得的这样的优势

- 索引对查询的优化程度能够达到上百倍
- 对于mysql，更新操作较之其他操作显得尤为耗时
- MongoDB在增删改查等方面消耗的时间近似

非结构化数据集实验

Experiment on Unstructured Datasets

时间控制

- 说明：25s
- 基础概念：1min40s
- 实验流程： 25s
- 技术细节一：1min
- 技术细节二：1min
- 结果分析：1min

HTML

- 超文本标记语言 (HyperText Markup Language)
- 标签的多重嵌套和属性的延拓性：二维表难以直接表达
- 固定的解析规则和结构： DOM Tree
- 标准的非结构化数据集

HTML

```
<html>
    <head>
        <meta http-equiv="X-UA-Compatible" content="IE=Edge">
        <script charset="utf-8" async="" src="http://xxx.xxx.php?dli=1 2 3 4 3 5"></script>
    </head>
    <body>
        <div class="qrcode-wrapper" id="layer" style="display: none">
            <p> It's an example </p>
        </div>
    </body>
</html>
```

DOM TREE

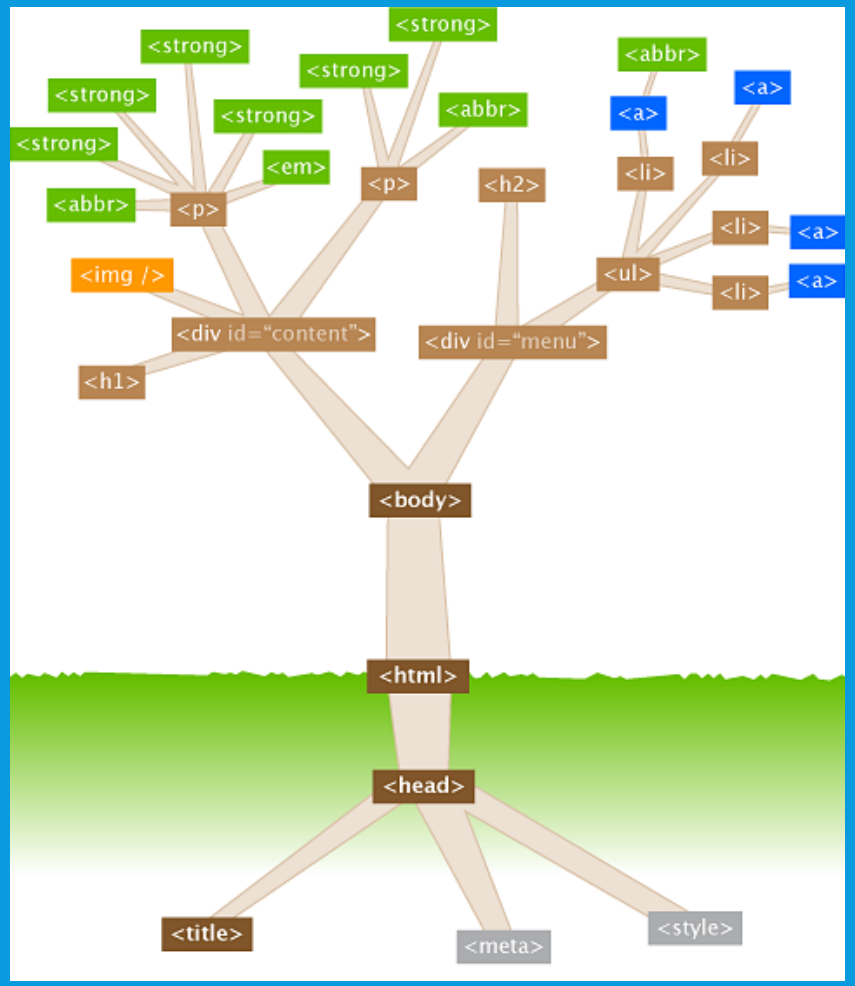

- 文档对象模型（英语：Document Object Model，缩写DOM）
- 将XML（包括HTML）文档解析为由多个节点组成的树形结构
- 元素节点、属性节点、文本节点等（整个xml文档视为一个文档节点）
- 所有的节点和最终的树状结构，都有规范的API，以达到使用编程语言操作文档的目的

爬虫

1.将 Start URL 加入解析队列

2.从队列中探出目标URL，通过伪造IP信息和http请求头部，欺骗服务器，获取HTML文本信息

3.解析HTML文本，筛选有用信息，DownLoad至本地

4.提取HTML文本中的链接，形成新的目标URL，判重后加入解析队列

5.队列为空时，结束 Crawling

- 实验中 Start URL 为交大教务处网站首页地址
- 实验中通过 Scrapy 部署 Python 爬虫

流程简述

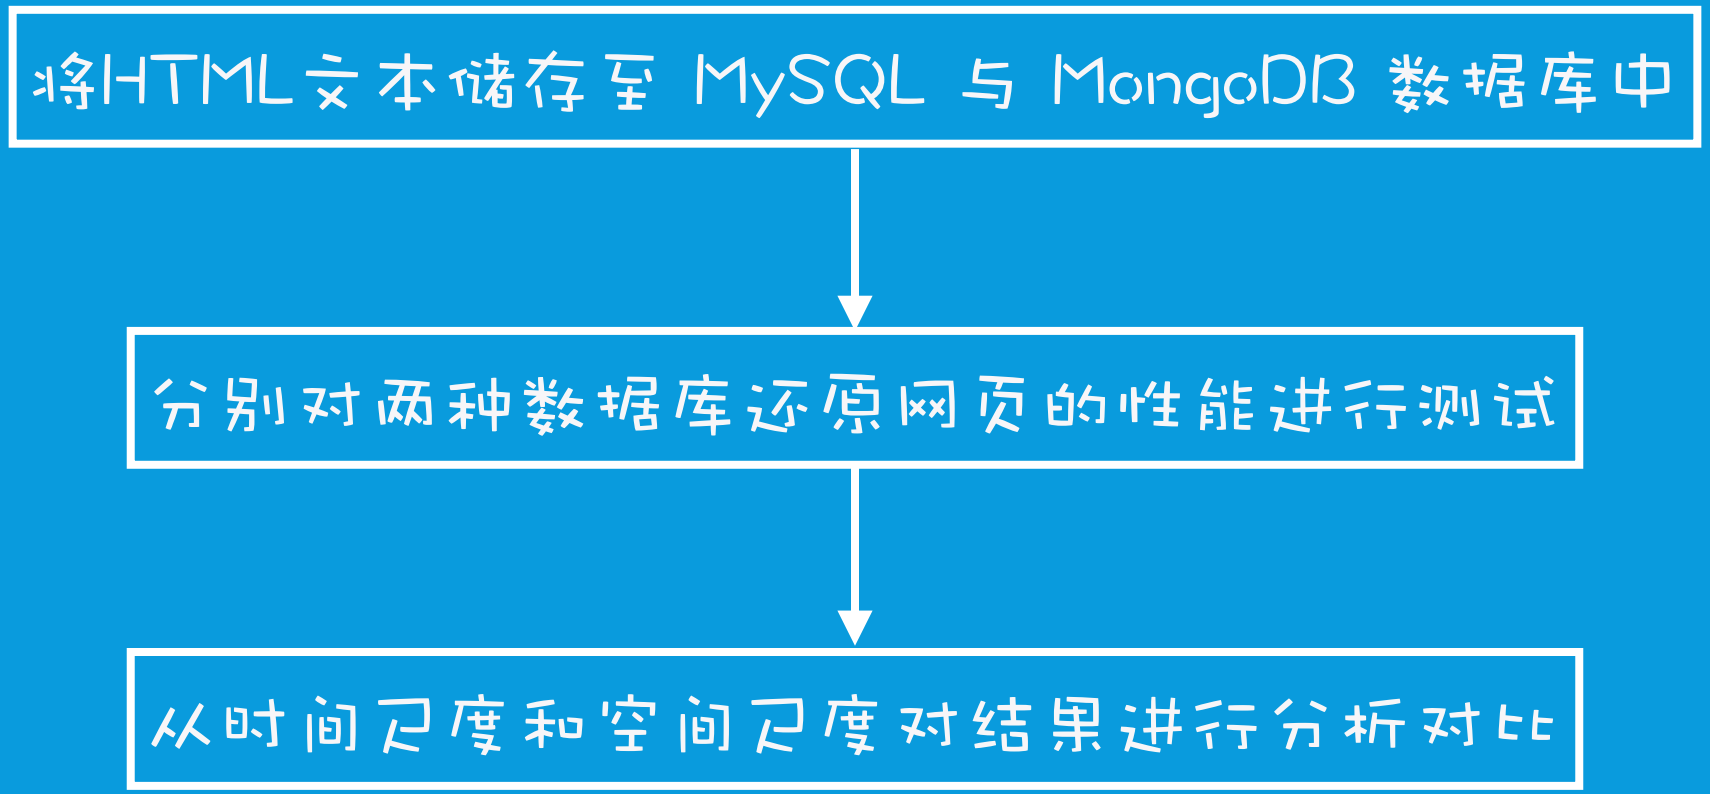
将HTML文本储存至 MySQL 与 MongoDB 数据库中
分别对两种数据库还原网页的性能进行测试
从时间尺度和空间尺度对结果进行分析对比

网页解析

SQL

- 解析Html文件为能够被二维表表达的结构（Get_SQL.py）存入 MySQL

NOSQL

1. 解析Html文件为Json字符串格式（Get_NoSQL.py）存入 MongoDB

Table one: Main

URL	Type	Father	Key （main key）
http://www.baidu.com	#text	1234	1235

Table the: Value

Key （main key）	Value
1235	It%20is%20an%20example.

网页还原，孰优孰劣？

SQL

1. 确定获取网页还原所需信息应执行的sql语句序列（如此复杂以至于需要用脚本来生成这些语句）
2. 依次执行sql语句获取节点信息，进而还原DOM树结构，保存为Json字符串形式（SQL2Json.py）
3. 还原Html文件（Json2Html.py）

NOSQL

1. 执行一次读操作，获取Json数据
2. 还原Html文件（Json2Html.py）

为保障实验结果的可靠性：Get_SQl.py、Get_NoSQL.py、SQL2Json.py、Json2Html.py 的主要算法部分均由小组成员编写，避免了引入模块造成的性能缺陷

整个实验流程中使用了包括 DFS BFS 表达式解析 AC自动机等多种算法

结果

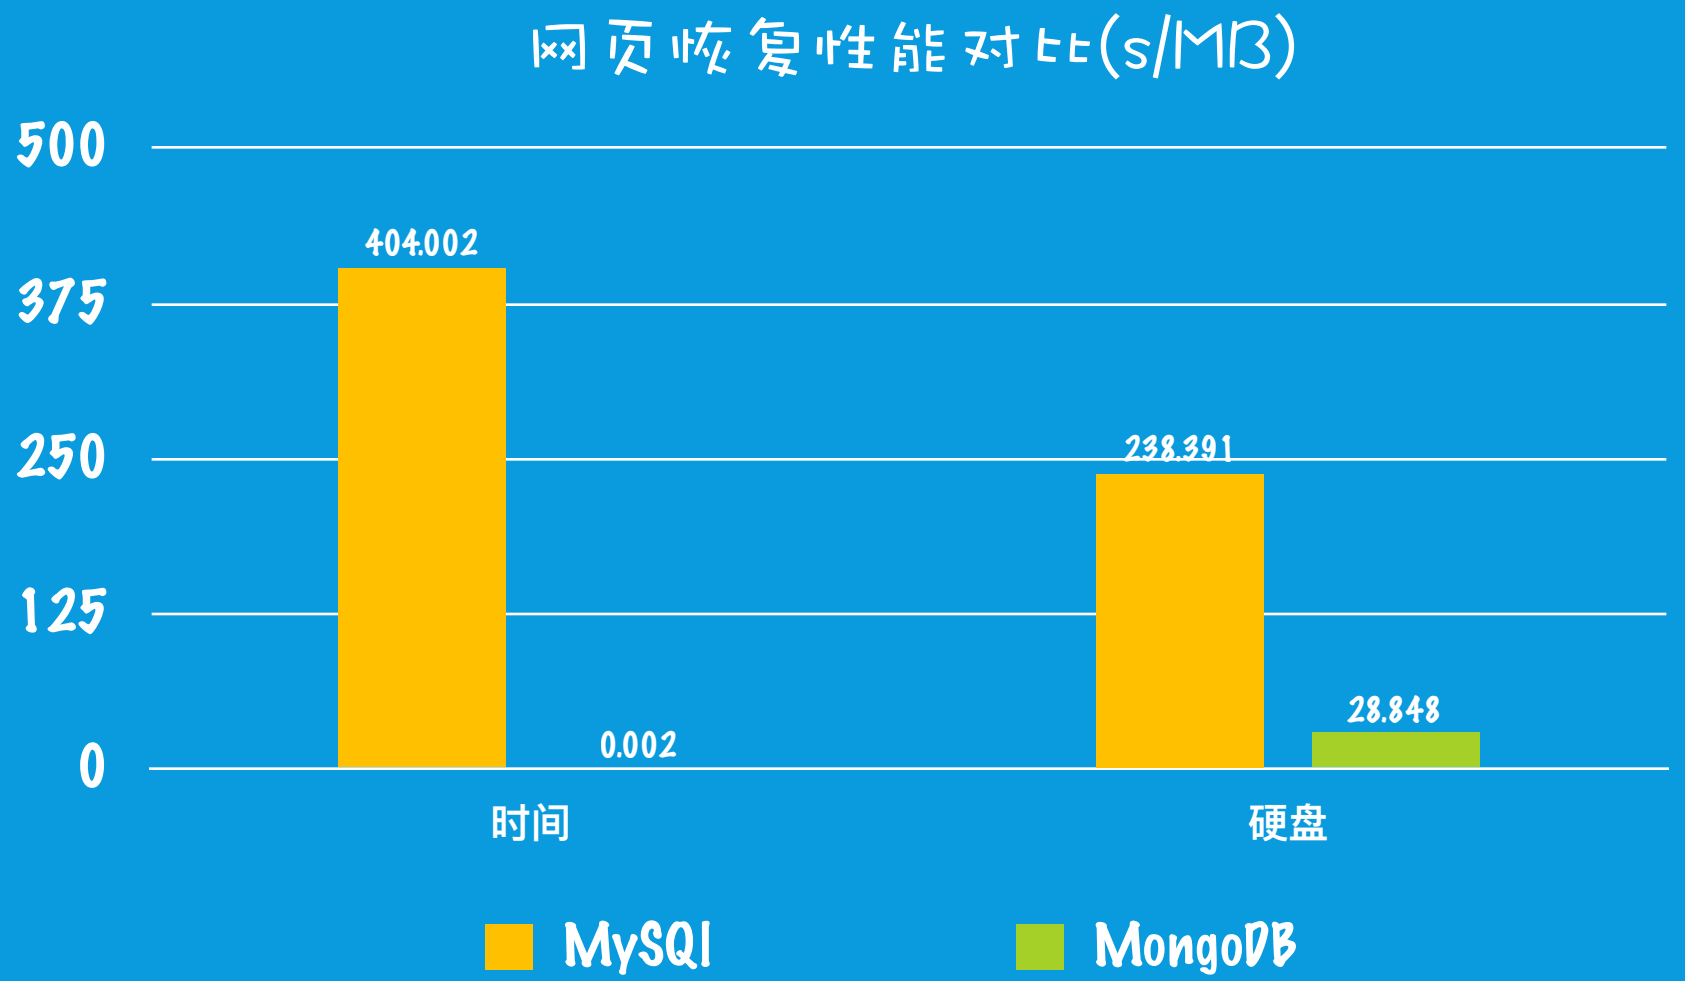
网页恢复性能对比(s/MB)
500
375
250
125
0
404.002
0.002
238.391
28.848
时间
硬盘
MySQl
MongoDB

结论

SQL

- 单单查询操作就需几十秒近一分钟，为NoSQL的十多万倍
- 逻辑复杂，不考虑还原过程就已需几百行代码进行辅助工作
- 存储麻烦，需将每个html分解为数千个节点以便存于sql数据库

NOSQL

- 所耗时间为毫秒级
- 逻辑简单，一次查询操作加即可完成
- 存储方便，将 Html 解析为可存储的 Json 十分简单

NoSQL在处理非结构化的数据上优势巨大，完虐SQL！

总结

结论

- mysql 速度逊于nosql，优点在于可以灵活处理结构化数据，长期的发展使得其在很多方面比较成熟
- nosql 在处理非结构化数据上能力很强，但处理结构化的数据却难以实现复杂的逻辑
- 总的来说，正如之前提到的那样，各种技术各有千秋，可以在适宜的场景发挥相应的作用

- 同时不得不提到的是，随着大数据的冲击和Web2.0时代的到来，非结构化或者超量结构化数剧登上时代的舞台，结构化的数据库必将向非结构化进行演化和拓展。事实上 Mysql 5.7 已经迈出了这一步！

GITHUB

- 因为时间有限，我们并没有把我们整个实验展现出来
- 所以我们把相关的材料，程序/脚本的源代码都放到了github上
- 如果大家想重现或者改进我们的项目，可以通过扫描这个二维码查看我们的项目
- 欢迎大家对我们的项目commit

功能展示网页

我们将我们的成果以网页的形式展现在了服务器上

欢迎同学们扫码体验

最后，请同学们不要DDoS不要注入攻击，小服务器不容易 @(・●・)@

参考文献

- [1]Li Y, Manoharan S. A performance comparison of SQL and NoSQL databases[C]// Communications, Computers and Signal Processing (PACRIM), 2013 IEEE Pacific Rim Conference on. IEEE, 2013: 15-19.
- [2]Li X, Zhou W. Performance Comparison of Hive, Impala and Spark SQL[C]//Intelligent Human-Machine Systems and Cybernetics (IHMSC), 2015 7th International Conference on. IEEE, 2015, 1: 418-423.
- [3]Aboutorabi S H, Rezapour M, Moradi M, et al. Performance evaluation of SQL and MongoDB databases for big e-commerce data[C]//Computer Science and Software Engineering (CSSE), 2015 International Symposium on. IEEE, 2015: 1-7.
- [4]Van der Veen J S, Van der Waaij B, Meijer R J. Sensor data storage performance: Sql or nosql, physical or virtual[C]//Cloud Computing (CLOUD), 2012 IEEE 5th International Conference on. IEEE, 2012: 431-438.
- [5]Schmid S, Galicz E, Reinhardt W. WMS performance of selected SQL and NoSQL databases[C]// Military Technologies (ICMT), 2015 International Conference on. IEEE, 2015.

任务分工

肖子彤：结构化数据下MySQL的部署与测试

SQL查询语句生成及 SQL2Json 功能实现

张倬　：编写部署爬虫爬取HTML文本信息

Get_SQL、Get_NoSQL、Json2HTML 功能实现

谭凌霄：结构化数据下MongoDB的部署与测试

展示网页的编写与展示平台服务器端的部署

THANKS